



TRƯỜNG ĐẠI HỌC SÀI GÒN

Khoa Công nghệ thông tin

BÁO CÁO BÀI TẬP

MÔN:

*Phân tích khám phá dữ liệu (EDA), trực quan hóa và rút trích Insights
từ tập dữ liệu Iris (Iris Flower Dataset)*

Sinh viên thực hiện:

MSSV:

Lớp:

MỤC LỤC

1. Giới thiệu tổng quan và mục tiêu phân tích	3
2. Cấu trúc tập dữ liệu và thống kê mô tả	3
2.1. Nguồn gốc dữ liệu và định nghĩa thuộc tính	3
2.2. Kiểm tra tính toàn vẹn và phân bố nhãn	3
2.3. Bảng thống kê mô tả (Descriptive Statistics)	3
3. Trực quan hóa và phân tích phân phối đơn biến	4
3.1. Phân tích phân phối và điểm ngoại lai qua Boxplot	4
3.2. Phân tích phân phối tần số qua Histogram	4
4. Phân tích tương quan và mối liên hệ đa biến	5
4.1. Ma trận hệ số tương quan Pearson	5
4.2. Ma trận tán xạ tổng quát (Scatter Matrix)	5
5. Phân tích chuyên sâu khả năng phân tách loài qua Pairplot	6
5.1. Phân bố không gian đa chiều theo 3 loài hoa	6
5.2. Khảo sát chi tiết phân tách trên thuộc tính Cánh hoa (Petal)	6
6. Tổng hợp Insights và Đề xuất ứng dụng Học máy	7
6.1. Các Insights cốt lõi từ dữ liệu (Key Insights)	7
6.2. Đánh giá tính khả thi và ranh giới phân loại	7
6.3. Khuyến nghị lựa chọn mô hình Machine Learning	7
7. Kết luận và Ghi chú triển khai	8
7.1. Kết luận tổng quan	8
7.2. Ghi chú triển khai mã nguồn	8
8. Tài liệu tham khảo	8

1. Xác định bài toán và mục tiêu phân tích

Tập dữ liệu Iris (Iris Flower Dataset) do nhà sinh vật học Ronald Fisher công bố năm 1936 là bộ dữ liệu kinh điển trong phân tích thống kê và học máy. Mục tiêu của bài thực hành là thực hiện phân tích khám phá dữ liệu (EDA), trực quan hóa các thuộc tính hình thái học, tìm hiểu mối quan hệ tương quan giữa các chiều đo và đánh giá khả năng phân tách giữa 3 loài hoa Iris nhằm làm tiền đề cho việc xây dựng các mô hình phân lớp.

- Khám phá phân phối thống kê của đài hoa (Sepal) và cánh hoa (Petal).
- Phát hiện các giá trị ngoại lai (Outliers) và kiểm tra tính toàn vẹn dữ liệu.
- Phân tích tương quan cặp biến (Correlation & Scatter Matrix).
- Đánh giá ranh giới phân tách 3 loài hoa (Setosa, Versicolor, Virginica) qua biểu đồ Pairplot.

2. Cấu trúc tập dữ liệu và thống kê mô tả

2.1. Nguồn gốc dữ liệu và định nghĩa thuộc tính

Thuộc tính	Kiểu dữ liệu	Đơn vị	Ý nghĩa sinh học / Mô tả
sepal-length	Float64	cm	Chiều dài lá đài hoa (Sepal)
sepal-width	Float64	cm	Chiều rộng lá đài hoa (Sepal)
petal-length	Float64	cm	Chiều dài cánh hoa (Petal)
petal-width	Float64	cm	Chiều rộng cánh hoa (Petal)
class	String / Obj	Nhãn	Loài hoa: Iris-setosa, Iris-versicolor, Iris-virginica

2.2. Kiểm tra tính toàn vẹn và phân bố nhãn

Kiểm tra hàm `df.info()` và `df.shape` xác định tập dữ liệu gồm 150 mẫu quan sát, không có giá trị khuyết thiếu (0 missing values trên cả 5 trường). Phân bố nhãn hoàn toàn cân bằng với đúng 50 mẫu cho mỗi loài (tỷ lệ 1:1:1), loại bỏ hoàn toàn rủi ro sai lệch do mất cân bằng lớp (Class Imbalance).

2.3. Bảng thống kê mô tả (Descriptive Statistics)


Thuộc tính	Count	Mean	Std	Min	25%	Median	75%	Max
sepal-length	150	5.84 cm	0.83	4.30	5.10	5.80	6.40	7.90
sepal-width	150	3.05 cm	0.43	2.00	2.80	3.00	3.30	4.40
petal-length	150	3.76 cm	1.76	1.00	1.60	4.35	5.10	6.90
petal-width	150	1.20 cm	0.76	0.10	0.30	1.30	1.80	2.50

Nhận xét sơ bộ: Thuộc tính cánh hoa (Petal Length và Petal Width) có độ lệch chuẩn (Std) và khoảng biến thiên (Max - Min) vượt trội so với đài hoa (Sepal), báo hiệu rằng cánh hoa chứa lượng thông tin phân biệt (variance) lớn hơn nhiều.

3. Trực quan hóa và phân tích phân phối đơn biến

3.1. Phân tích phân phối và điểm ngoại lai qua Boxplot

Biểu đồ Boxplot phân phối 4 đặc trưng tập dữ liệu Iris




Nhận xét biểu đồ Boxplot:

- Trung vị và khoảng tứ phân vị (IQR): Sepal Length và Sepal Width có dải hộp tương đối gọn gàng, đối xứng. Ngược lại, Petal Length và Petal Width có khoảng tứ phân vị rộng lớn phản ánh sự đa dạng mạnh về kích thước.
- Nhận diện điểm ngoại lai (Outliers): Thuộc tính Sepal Width là đặc trưng duy nhất phát hiện các điểm ngoại lai (outliers) nằm ngoài 1.5 * IQR (các giá trị < 2.05 cm và > 4.05 cm). Ba thuộc tính còn lại không có giá trị ngoại lai dị biệt.

3.2. Phân tích phân phối tần số qua Histogram

Biểu đồ Histogram tần số xuất hiện của 4 thuộc tính




Nhận xét biểu đồ Histogram:

- Phân phối chuẩn (Gaussian): Sepal Length và Sepal Width thể hiện phân phối đơn đỉnh gần như đối xứng dạng hình chuông.
- Phân phối lưỡng đỉnh (Bimodal Distribution): Petal Length và Petal Width thể hiện rõ 2 đỉnh tách biệt rõ nét: một nhóm mẫu tập trung ở kích thước rất bé (Petal Length 1-2 cm, Petal Width 0.1-0.6 cm) và một nhóm lớn hơn trải dài từ 3-7 cm. Đây là dấu hiệu định lượng rõ ràng cho thấy dữ liệu tự nhiên đã phân hóa thành các cụm riêng biệt.

4. Phân tích tương quan và mối liên hệ đa biến

4.1. Ma trận hệ số tương quan Pearson

Ma trận hệ số tương quan Pearson giữa các thuộc tính



Hệ số tương quan (r) tiêu biểu

Petal Length & Petal Width	+0.963	Cực mạnh
Sepal Length & Petal Length	+0.872	Rất mạnh
Sepal Length & Petal Width	+0.818	Mạnh
Sepal Length & Sepal Width	-0.118	Rất yếu
Sepal Width & Petal Length	-0.428	Nghịch vừa
Sepal Width & Petal Width	-0.366	Nghịch vừa

- Tương quan tuyến tính cực mạnh giữa Petal Length và Petal Width ($r = 0.963$) chứng minh khi cánh hoa dài ra thì bề rộng cũng tăng tương ứng.
- Sepal Width có xu hướng ngược chiều với kích thước cánh hoa.

4.2. Ma trận tán xạ tổng quát (Scatter Matrix)

Ma trận phân tán Scatter Matrix tổng quát




Đánh giá Scatter Matrix:

Ma trận tán xạ cho phép quan sát đồng thời phân phối đơn biến (trên đường chéo) và tương quan 2 biến (ngoài đường chéo):

- Tính tuyến tính rõ rệt:
Các điểm dữ liệu tạo thành vệt hẹp xiên chéo giữa Petal Length và Petal Width.
- Phân cụm tự nhiên:
Hầu hết các cặp đồ thị có sự hiện diện của Petal đều xuất hiện một khoảng trống (gap) tách biệt 1 cụm biệt lập ở góc dưới bên trái, trong khi cụm còn lại kéo dài lên góc trên bên phải.

5. Phân tích chuyên sâu khả năng phân tách loài qua Pairplot


5.1. Phân bố không gian đa chiều theo 3 loài hoa



Phân tích đặc tính phân tách từng loài:

- Loài Iris-setosa (Màu xanh lam): Hoàn toàn tách biệt tuyến tính (Linearly Separable) với hai loài còn lại. Trên mọi biểu đồ chiều liên quan đến Petal Length (< 2.0 cm) và Petal Width (< 0.8 cm), Setosa đứng độc lập hoàn toàn. Bất kỳ thuật toán phân loại đơn giản nào cũng có thể đạt độ chính xác 100% khi nhận diện Setosa.
- Loài Iris-versicolor (Màu cam) và Iris-virginica (Màu xanh lá): Hai loài này có kích thước lớn hơn và có một vùng chồng lấn ranh giới (Boundary Overlap) ở khoảng Petal Length (4.5 - 5.1 cm) và Petal Width (1.5 - 1.8 cm).

5.2. Khảo sát chi tiết phân tách trên thuộc tính Cánh hoa (Petal)



Kết luận không gian 2 chiều Petal:

- Chỉ cần sử dụng 2 đặc trưng Petal Length và Petal Width:
- Ranh giới tuyến tính 1: Đường thẳng Petal Length = 2.5 cm phân loại chính xác 100% Setosa.
 - Ranh giới phân chia 2: Đường phân cách tuyến tính hoặc đa thức bậc 2 có thể tách biệt Versicolor và Virginica với độ chính xác vượt trội $> 96\%$.
 - Hai đặc trưng Sepal đóng vai trò hỗ trợ tinh chỉnh ở các mẫu nằm sát ranh giới giao thoa.

6. Tổng hợp Insights và Đề xuất ứng dụng Học máy (Machine Learning)

6.1. Các Insights cốt lõi từ dữ liệu (Key Insights)

Insight 1 — Tầm quan trọng của Cánh hoa (Petal Dominance):

Cánh hoa (Petal) là nhân tố quyết định khả năng phân loại. Độ biến thiên và tính phân cụm của Petal Length / Width vượt trội hoàn toàn so với Sepal. Trong mô hình Decision Tree, thuộc tính Petal luôn được chọn làm nút gốc (Root Node).

Insight 2 — Tính khả tách của Setosa (Linear Separability):

Setosa là cụm độc lập tuyệt đối. Không cần đến các thuật toán phức tạp, một luật đơn giản (Rule-based: Petal-length < 2.5 cm) đủ để phân lớp chính xác 100%.

Insight 3 — Vùng giao thoa Versicolor vs Virginica:

Ranh giới giữa 2 loài này mang tính liên tục sinh học. Các mô hình Soft-margin hoặc hạt nhân RBF (SVM), K-Nearest Neighbors (k = 3 hoặc 5) sẽ xử lý tối ưu vùng biên giới này hơn là mô hình Hard-margin.

Insight 4 — Chất lượng dữ liệu hoàn hảo:

Tập dữ liệu sạch 100% không missing values, nhãn cân bằng tuyệt đối (50:50:50). Do đó, chỉ số Accuracy hoàn toàn đáng tin cậy để đánh giá hiệu năng mà không sợ bias mất cân bằng dữ liệu.

6.2. Đánh giá tính khả thi và ranh giới phân loại

Khảo sát cho thấy bài toán phân loại 3 loài hoa Iris là hoàn toàn khả thi với độ chính xác kỳ vọng từ 96% đến 99%. Hiện tượng quá khớp (Overfitting) có thể xảy ra nếu dùng các mô hình quá phức tạp (Deep Neural Networks nhiều lớp), vì vậy các mô hình tinh gọn, có khả năng diễn giải cao (Explainable AI) được khuyến nghị hàng đầu.

6.3. Khuyến nghị lựa chọn mô hình Machine Learning

Mô hình đề xuất	Loại bài toán	Đặc điểm nổi bật & Khuyến nghị cấu hình
Logistic Regression / Softmax	Phân loại có giám sát	Độ chính xác cao (~96%), tốc độ hội tụ nhanh, dễ giải thích trọng số.
Support Vector Machine (SVM)	Phân loại có giám sát	Linear Kernel hoặc RBF Kernel với C=1.0 cho lề phân cách tối ưu nhất.
K-Nearest Neighbors (KNN)	Phân loại có giám sát	Hiệu quả cao với cụm dữ liệu cục bộ; tối ưu với k = 3 hoặc k = 5.
Decision Tree / Random Forest	Phân loại có giám sát	Trực quan hóa cây điều kiện if-else hoàn hảo, xác định rõ Feature Importance.
K-Means Clustering	Học không giám sát	Phân cụm tự nhiên với k = 3; đạt độ tương thích cao với nhãn thực tế.
Phân tích PCA (Principal Comp.)	Giảm chiều dữ liệu	2 thành phần chính (PC1, PC2) giữ > 95% phương sai thông tin toàn bộ tập mẫu.

7. Kết luận và Ghi chú triển khai

7.1. Kết luận tổng quan

Thông qua quá trình phân tích khám phá dữ liệu (EDA) và trực quan hóa chi tiết trên tập dữ liệu Iris:

- Chúng ta đã làm rõ cấu trúc 4 đặc trưng hình thái thực vật học và xác nhận chất lượng dữ liệu đạt chuẩn hoàn hảo.
- Phân tích đơn biến và đa biến đã chứng minh vai trò then chốt của các thuộc tính Cánh hoa (Petal) so với Đài hoa (Sepal).
- Kết quả khẳng định loài Iris-setosa hoàn toàn phân tách tuyến tính, trong khi Iris-versicolor và Iris-virginica có thể được phân loại chính xác cao bằng các mô hình máy học phổ biến như SVM, Logistic Regression, KNN hay Random Forest.
- Phân tích EDA đóng vai trò là kim chỉ nam định hướng cho toàn bộ giai đoạn kỹ thuật đặc trưng (Feature Engineering) và lựa chọn kiến trúc thuật toán trong bài toán học máy.

7.2. Ghi chú triển khai mã nguồn

Toàn bộ quy trình nạp dữ liệu, tiền xử lý, tính toán thống kê mô tả và sinh các biểu đồ trực quan hóa được hiện thực đầy đủ và đồng bộ trong tệp Jupyter Notebook: `datav.ipynb`.

- Môi trường thực thi: Python 3, tương thích Google Colab và JupyterLab.
- Các thư viện nền tảng: pandas (xử lý khung dữ liệu), numpy (tính toán số học), matplotlib và seaborn (vẽ đồ thị).
- Cấu trúc thư mục dự án: Tệp mã nguồn `datav.ipynb` cùng tệp báo cáo chi tiết này được tổ chức chuyên nghiệp trong thư mục `Tuan02` của kho lưu trữ GitHub nhóm.

8. Tài liệu tham khảo

- [1] Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179-188.
- [2] UCI Machine Learning Repository. Iris Data Set. URL: <https://archive.ics.uci.edu/ml/datasets/iris>.
- [3] Brownlee, J. (2020). *Machine Learning in Python Step-By-Step*. Machine Learning Mastery.
- [4] McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.
- [5] Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- [6] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.